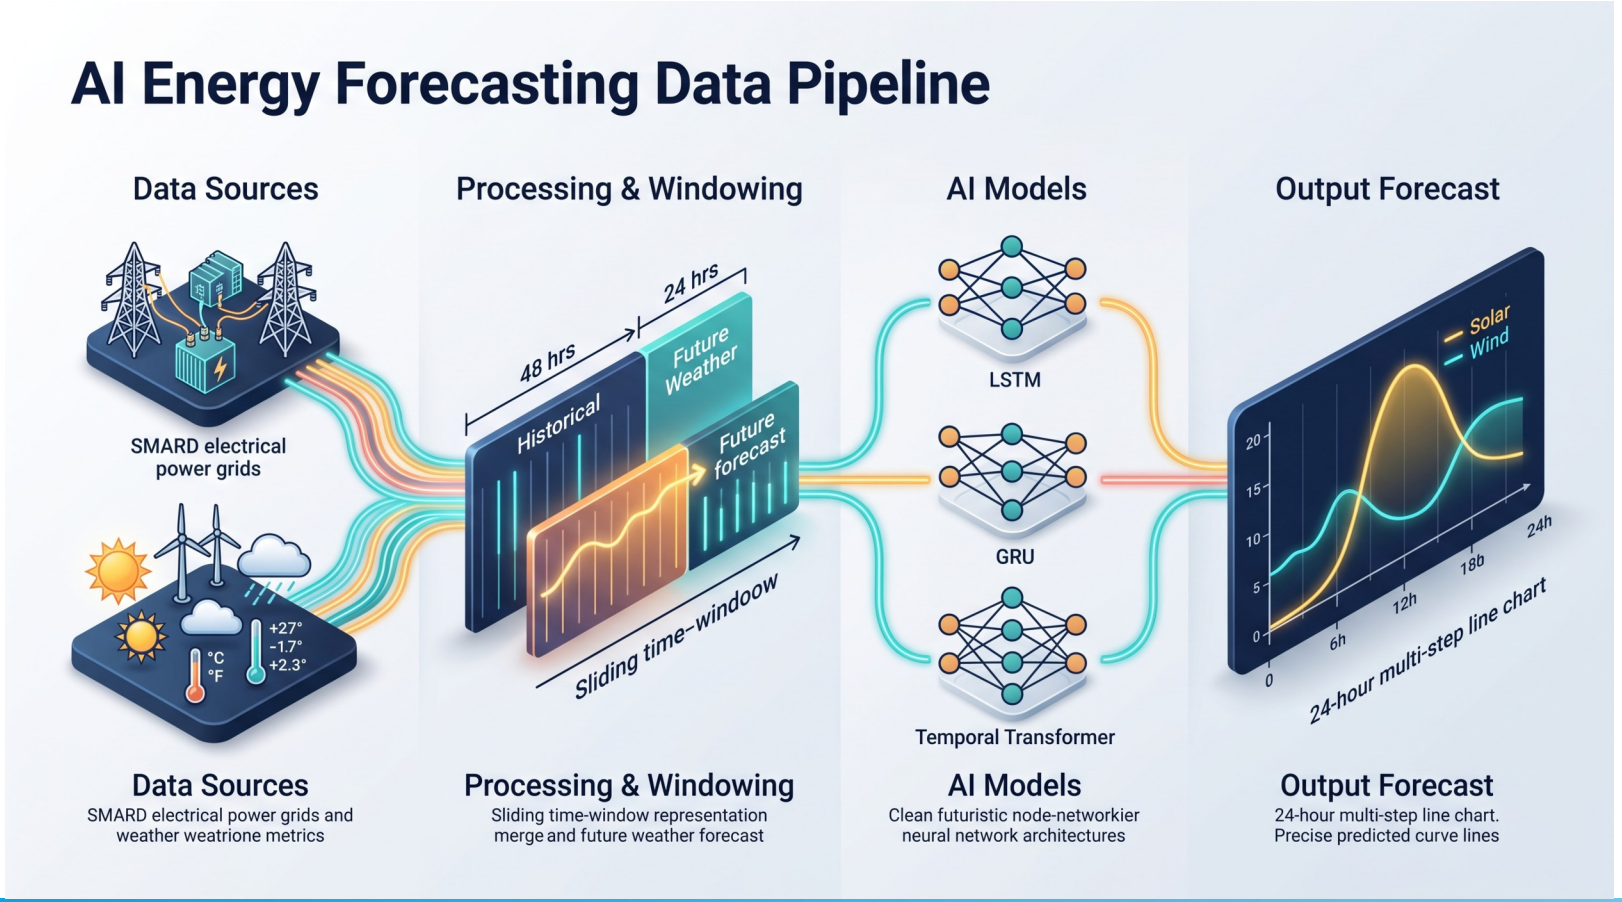
Deep-Learning-Projekt:
Prognose von Solar- und Windenergie

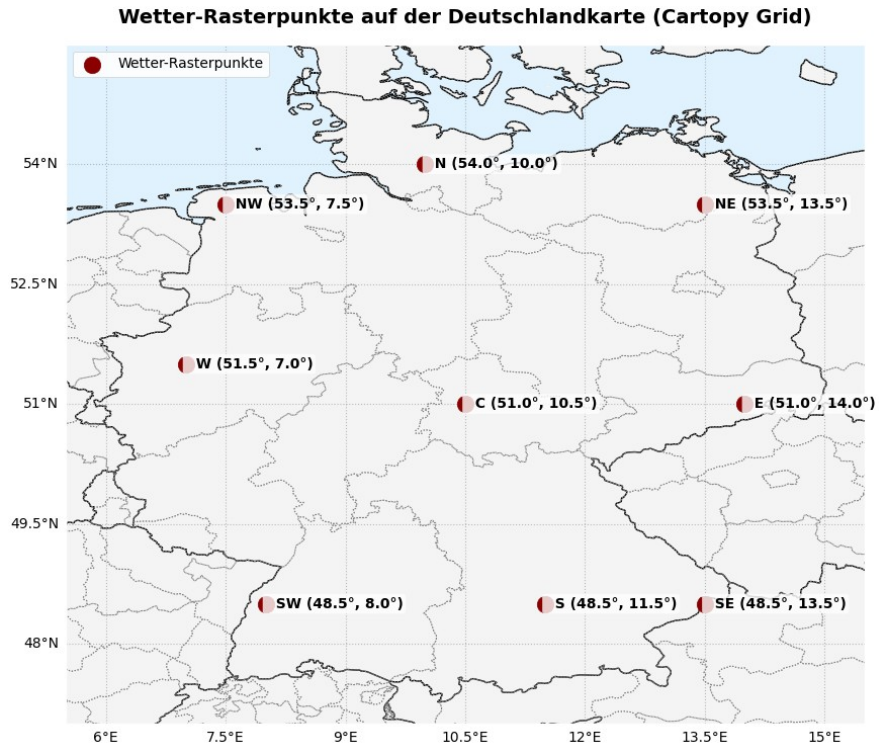
von Maksym Gachkivskyi

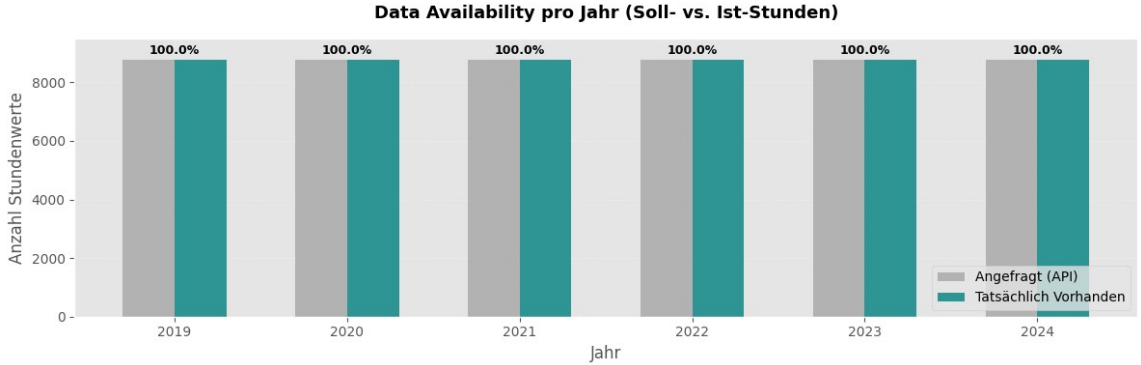
28.08.2026

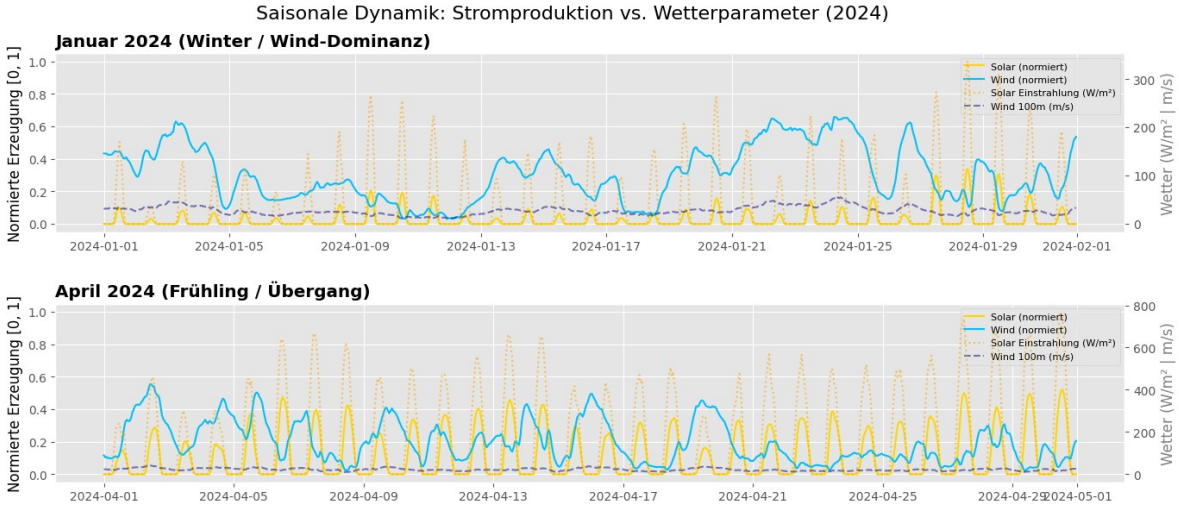
Projekt und Datenfluss



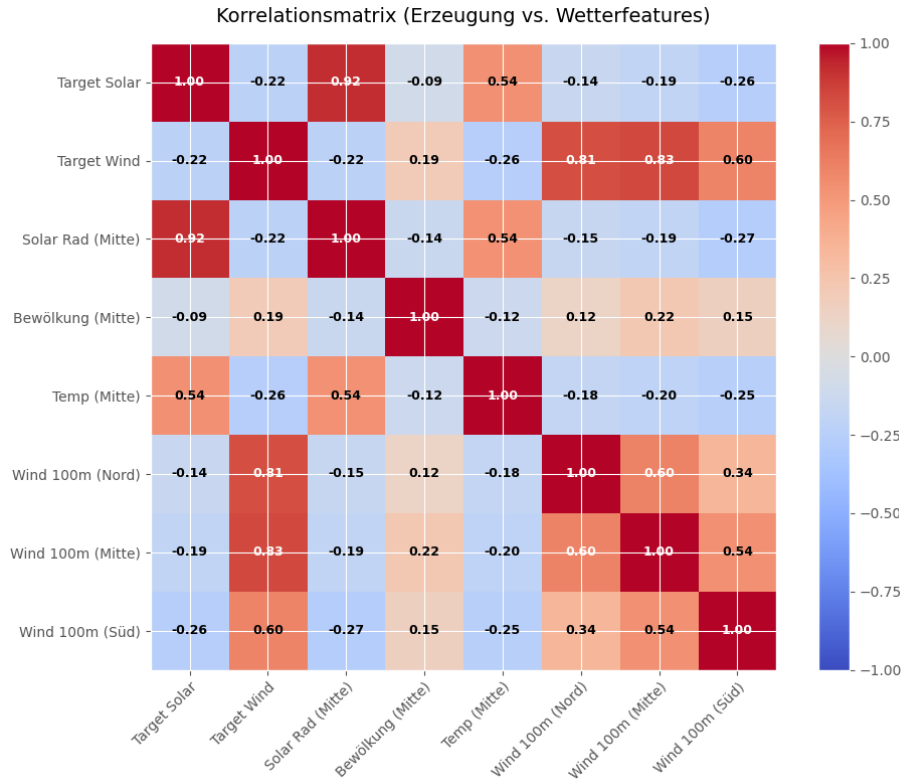
Datenübersicht

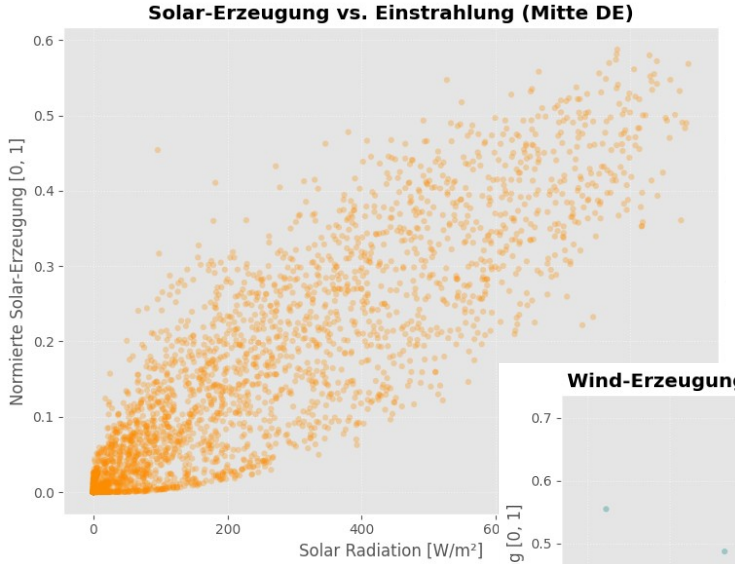


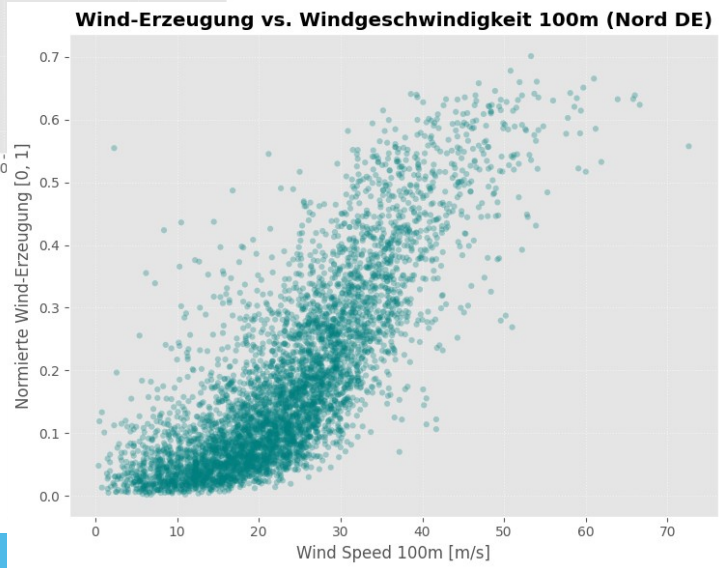




Einfache Abhängigkeiten







Hyperparameter-Testräume der Grid-Search

- **LSTM**:
- lookback_hours: [24, 48, 72]
- num_layers: [1, 2, 3]
- hidden_dim: [32, 64, 128]
- Lr: [0.001, 0.0005]
- Dropout: [0.0, 0.1, 0.2]
- use_skip: [True, False]

- **GRU:**
- lookback_hours: [24, 48, 72]
- num_layers: [1, 2, 3]
- hidden_dim: [32, 64, 128]
- Lr: [0.001, 0.0005]
- Dropout: [0.0, 0.1, 0.2]
- use_skip: [True, False]

- **Transformer**:
- lookback_hours: [24, 48, 72]
- num_enc/dec_layers: [1, 2]
- d_model: [64, 128]
- dim_feedforward: [128, 256]
- Lr: [0.001, 0.0005]
- Dropout: [0.0, 0.1, 0.2]

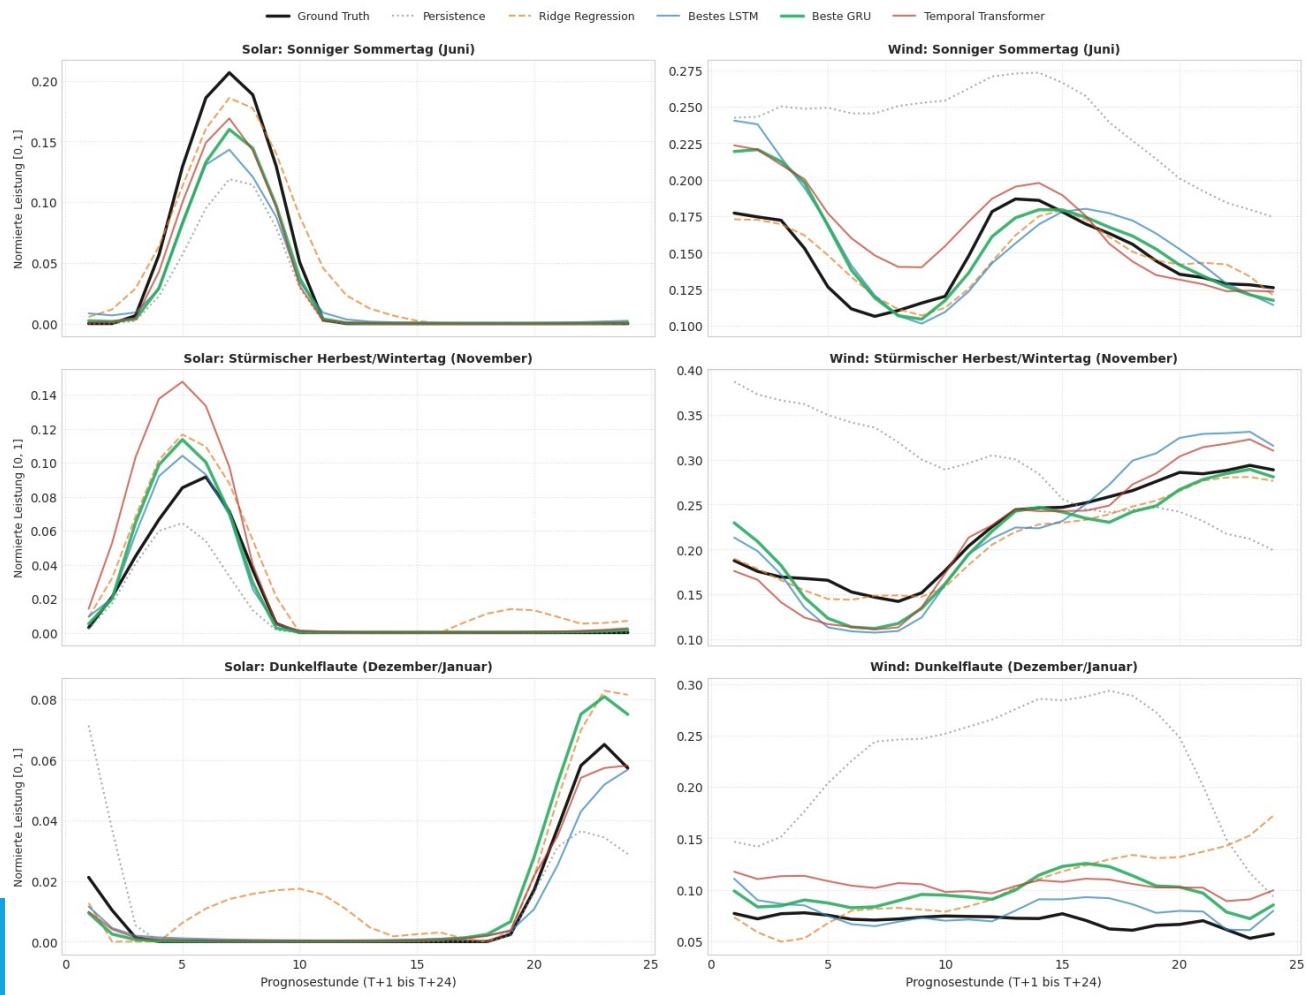
Die zentrale Benchmark-Tabelle, Test-Set 2024

Modell-Klasse	Konfiguration (Optimum)	Overall MAE	Overall RMSE	Solar MAE	Wind MAE	Param.	Lernzeit (s)	Inferenzzeit (ms)
Persistence	Naiv (24h Shift / Saisonal)	0.0629	0.1029	0.0214	0.1043	0	-	2.05
Ridge Regression	L2-Regularisiert (alpha=1.0)	0.0169	0.0255	0.0102	0.0237	180,912	5	3.43
Optimiertes LSTM	lookback=24h, layers=1, hid=128, lr=0.0005, dr=0.2, skip=True	0.0165	0.0260	0.0106	0.0224	198,018	164	4.19
Optimierte GRU	lookback=48h, layers=2, hid=128, lr=0.0005, dr=0.2, skip=False	0.0161	0.0251	0.0110	0.0211	346,306	1262	23.95
Temporal Transformer	lookback=48h, d_model=128, enc/dec=2, ff=128, lr=0.0005, dr=0.1	**0.0156**	**0.0246**	**0.0099**	**0.0213**	553,026	2006	19.65

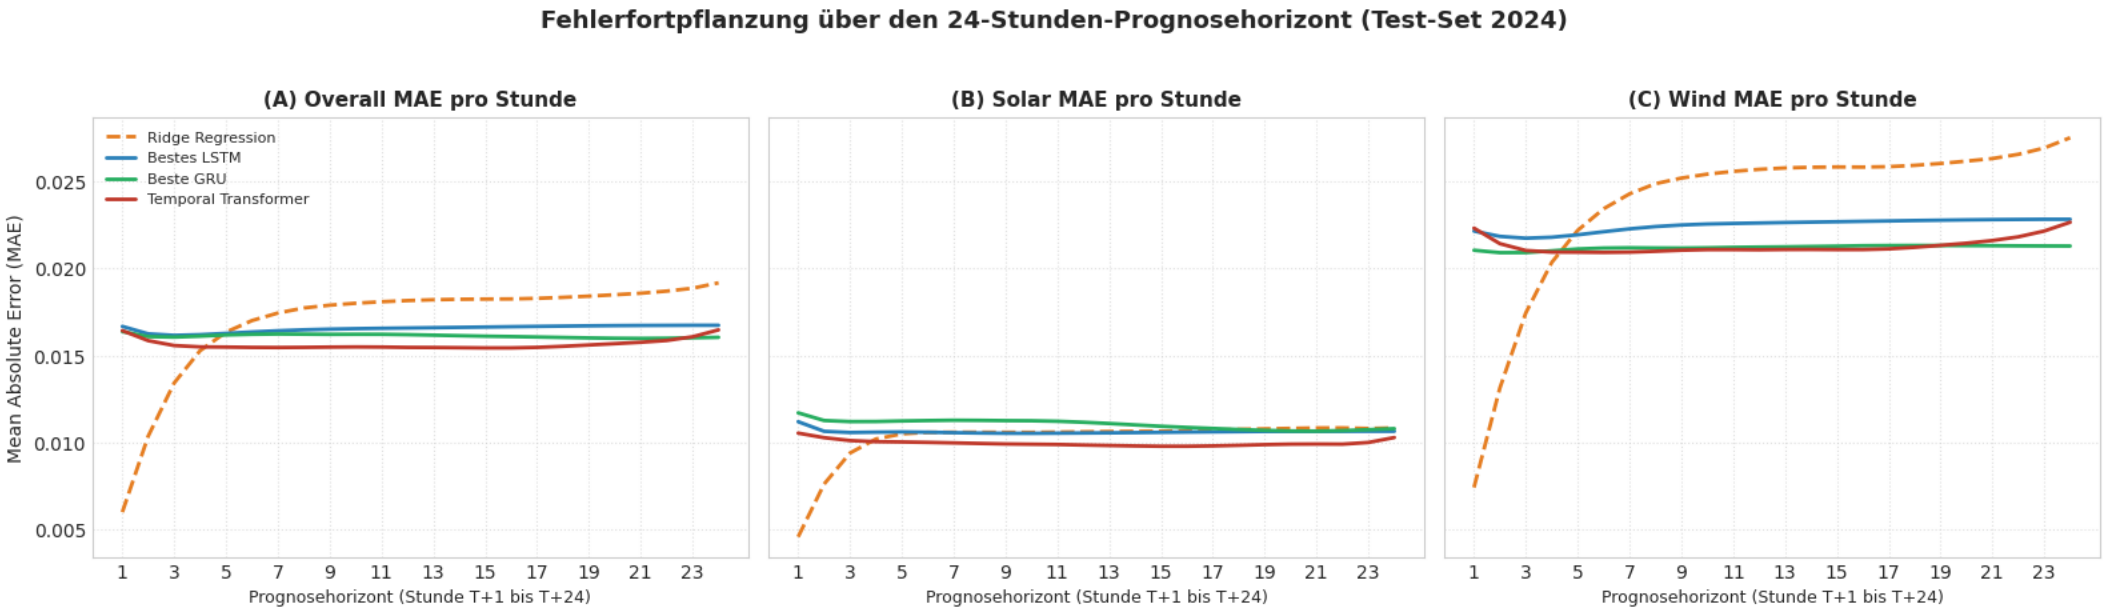
Train/Val Loss Verlauf mit Baseline-Linien



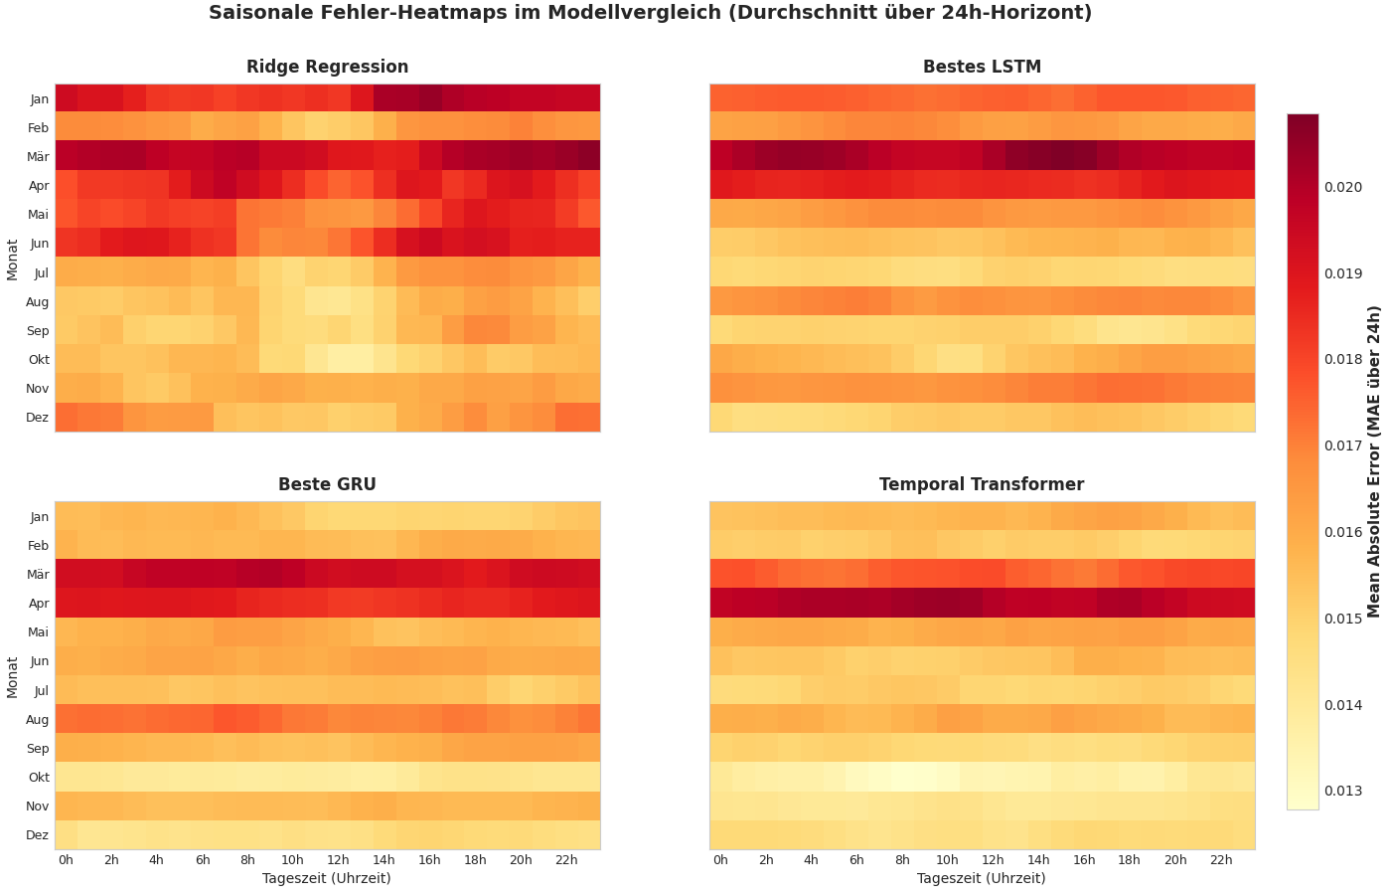
Tagesszenarien



Fehlerfortpflanzung, 24-Stunden-Prognosehorizont



Saisonalitäts- und Horizont-Analyse



Grenzen, Herausforderungen & Offene Probleme

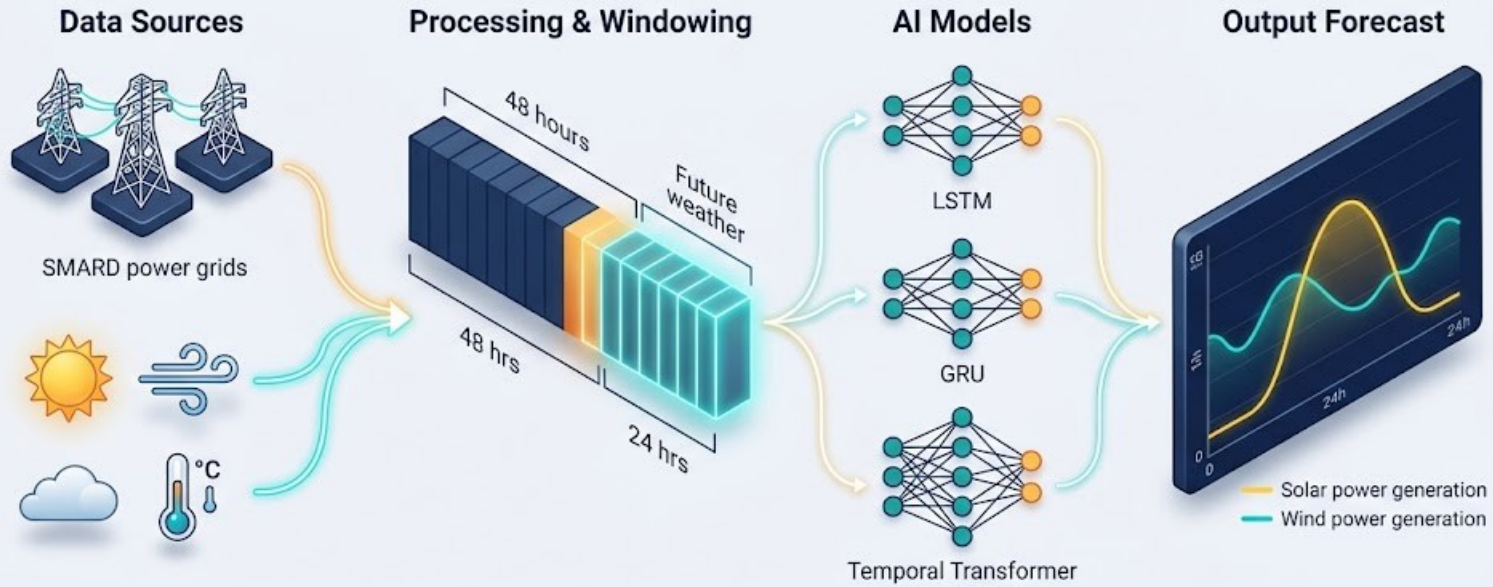
- Systematische Abweichungen bei Extremwerten:
  - Photovoltaik (Sommer): Symmetrische Loss-Funktionen (MSE) führen zur Dämpfung der Mittags-Peaks (zu konservative Ertragschätzung).
  - Wind & Solar (Herbst/Winter): Neigung aller Modelle zu leichten Überschätzungen bei stürmischen Wetterlagen.
- Saisonale Fehlerschwerpunkte (März & April):
  - Höchste Fehlerkonzentrationen in den Übergangsmonaten durch rasche Bewölkungs- und Windumschwünge.
- Modellkomplexität vs. Effizienz:
  - Hoher Rechenaufwand: Temporal Transformer benötigt >550k Parameter und lange Trainingszeiten (~3.400 s bei 72h Lookback).
  - Informations-Overload: Sequenzausdehnung auf 72h trägt ohne Feature-Selektion primär stochastisches Wetterrauschen ein.

Fazit & Nächste Schritte

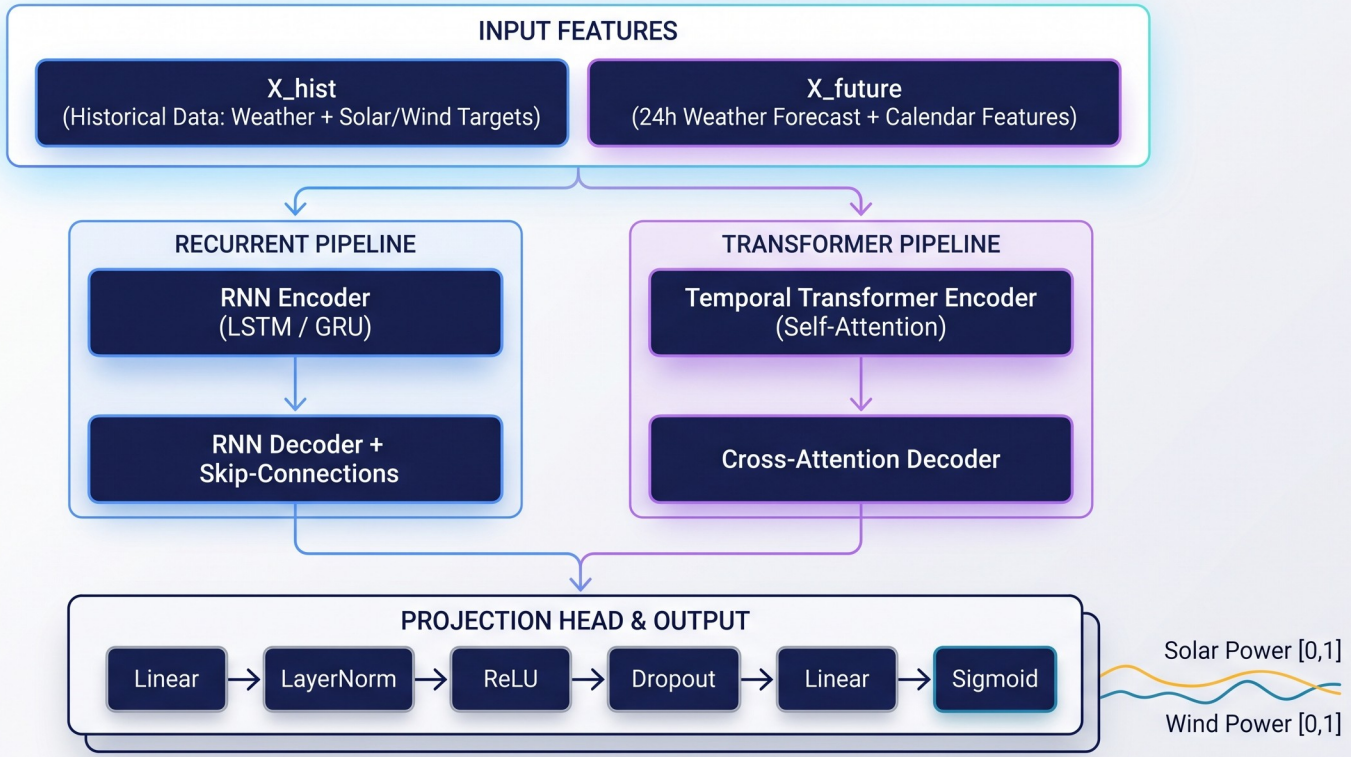
- Kernerkenntnisse:
  - Temporal Transformer als Gesamtsieger
  - Zeitliche Stabilität: Dank Cross-Attention nahezu fehlerfortpflanzungsfrei von T+1 bis T+24 (deutlich überlegen gegenüber Ridge Regression).
  - Optimaler Sweet Spot: 48h Historienfenster + Embedding-Dimension d_model= 128.
- Nächste Schritte & Forschungsansätze:
  - Probabilistisches Forecasting: Implementierung von Quantils-Regression (z. B. Pinball Loss für 10%- und 90%-Quantile) zur Unsicherheitsmessung.
  - Asymmetrische Loss-Funktionen: Einsatz von Weighted MSE zur Korrektur der Solar-Peak-Dämpfung zur Mittagszeit.

Anhang

AI Energy Forecasting Data Pipeline



DEEP LEARNING ENERGY FORECASTING SYSTEM



Saisonalitäts- und Horizont-Analyse

